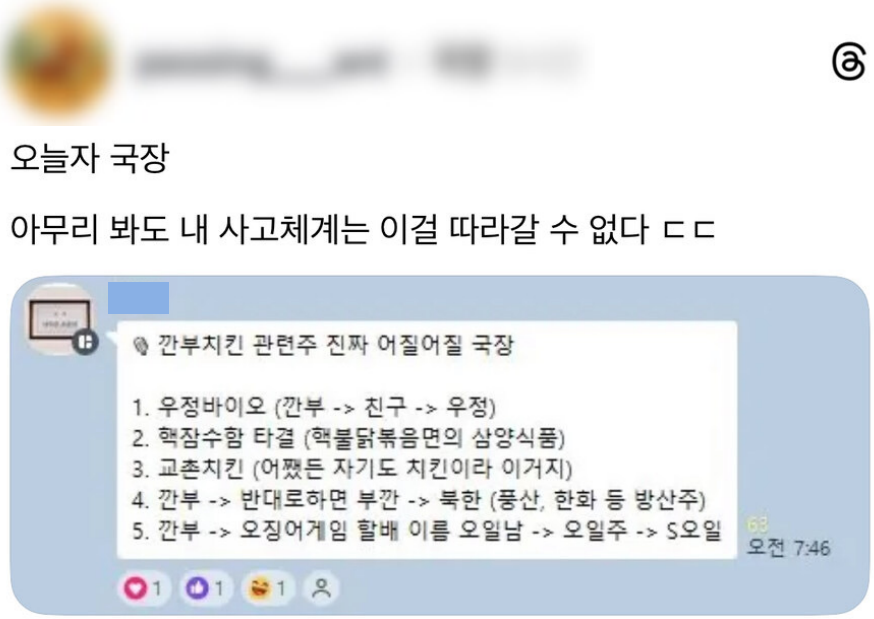
대시보드 QR코드

SNS 언급 급증과
국내 테마주 간의 연관 관계

2조 : 김동국, 윤지석, 이가은, 이해인, 장기열

01 문제 정의

국장 특유의 테마 반응





기존 시장 데이터로는 설명하지 못하는 주가 움직임이 있음

01 문제 정의

국내 시장의 급상승 테마 반응 유형

테마 전염형	특정 대장주나 특정 섹터의 호재가 연관된 다른 테마나 종목군으로 빠르게 확산
관계성 테마형	기업 간의 지분 관계, 공급망, 국책 과제 공동 참여 등 밀접한 사업적 연관성
군중 과열형	시장 참여자들의 심리적 쏠림 현상(포모, FOMO 등)과 거래대금 급증
이상 가격형	수급이나 뉴스에 비해 주가가 비정상적인 급등락을 보이는 괴리가 발생한 상태
뉴스 반전형	특정 호재나 악재 뉴스, 예상치 못한 공시에 의해 기존의 주가 흐름 급격히 반전

‘SNS 내 발생한 관심도의 변화’가 국내 주식의 특이한 패턴을 반영한 ‘주식 급등’과 연관이 있는지 확인

02 데이터 수집

분석 대상 선정

데이터 셋 구성 프로세스

키워드 : 30개

최근 국내 증시 테마 이슈 및 분야별 선정
(2024. 11 ~ 현재)

×

관련 종목 : 10개

키워드별 관련 종목

→

300

전체 고유 종목

테마 분류	키워드 개수	키워드 주요 예시	관련 종목 예시
AI·반도체·첨단기술	8	HBM, CXL, 양자컴퓨터, 데이터 센터, 피지컬 AI	네오셈, 엑스게이트
금융·정책·정치	7	스테이블코인, STO, 비상계엄	다날, 핑거, 신한지주
에너지·산업·국제 이슈	8	전력기기, SMR, K-방산	대한전선, 제룡전기
바이오·소비·성장 테마	7	비만치료제, 의료 AI, K-뷰티	펩트론, 루닛

30개 테마 키워드 × 각 10개 관련 종목 선정을 통해 총 300개의 고유 분석 종목 데이터 집합 구성

02 데이터 수집

데이터 결합 및 분석 데이터셋 구축

구분	출처	수집 항목	원자료 기간	분석 활용 목적
키워드 SNS 관심도	썸트렌드*	채널별 언급량 긍정·부정·중립 감성어	2024.10.04 ~ 2026.10.24	**시장 여론 영향력 측정** (화제성 규모 · 확산 경로 · 감성 변화)
종목 주가 정보	FinanceDataReader	종목 OHLCV KOSPI·KOSDAQ 지수	2024.10.02 ~ 2026.10.23	**수익률 및 가격변동성 분석** (시장 대비 성과 · 거래량 추이)
	OpenDART	공시 접수일 공시명	2024.09.02 ~ 2026.10.23	**실질 펀더멘털 요인 검증** (실적 · 공급계약 및 주요 증시)

*국내 온라인 언급량과 감성을 날짜별로 제공하는 소셜 빅데이터 서비스 플랫폼

키워드 · 날짜 연결 → **종목 × 거래일 분석표**

03 데이터 전처리

시장 변수 7개, SNS 변수 9개, y값 (정답라벨)

시장 변수 7개

구분	변수	정의	해석
주가 흐름	1일 초과수익률	당일 종목 수익률 – 시장 수익률	시장 움직임을 제외한 당일 상승·하락
	3일 초과수익률	최근 3거래일 시장 대비 수익률	단기 상승·하락 흐름
	20일 초과수익률	최근 20거래일 시장 대비 수익률	약 한 달간의 추세
거래량	5일 거래량 비율	당일 거래량 ÷ 직전 5거래일 평균	평소 대비 거래 집중 정도
변동성	20일 변동성	최근 20거래일 일별 수익률의 표준편차	평소 가격이 얼마나 흔들리는지 측정
공시	3일 공시 건수	최근 3거래일 접수된 공시 수	최근 기업 정보 발생 빈도 통제
	3일 공급계약 공시 여부	최근 3거래일 공급계약 체결 공시 유무(0/1)	계약 체결 공시 발생 여부 통제

출처 : 공시정보 - OpenDART / 주가흐름, 거래량, 변동성 - FinanceDataReader

시장 지수 흐름 및 개별 기업 공시 이력을 통제 변수로 활용하여 분석 정확도 확보

03 데이터 전처리

SNS 변수 9개

구분	변수	측정 내용
언급 규모	로그 언급량	온라인 관심 규모
언급 변화	28일 표준점수	평소 대비 이례적인 언급 급증 정도
	3·14일 모멘텀	최근 관심의 증가·감소 흐름
화제 단계	화제 기간 여부	관심 급증 이후 화제 지속 여부
	화제 시작 후 경과일	화제 시작일부터 지난 일수
감성	긍정 감성 비율	전체 감성어 중 긍정 비중
	긍정 비율 변화	직전 7일 평균 대비 긍정 비율 변화
	감성 표본 부족 여부	감성어 합계 10건 미만 여부
채널 확산	채널 다양성 변화	직전 7일 평균 대비 채널 다양성 변화

Y값 (정답 라벨)

예측 대상 - 급등 기준

다음 날 시가 ~ 이틀 뒤 종가

시장 대비 초과수익률

+5% 이상

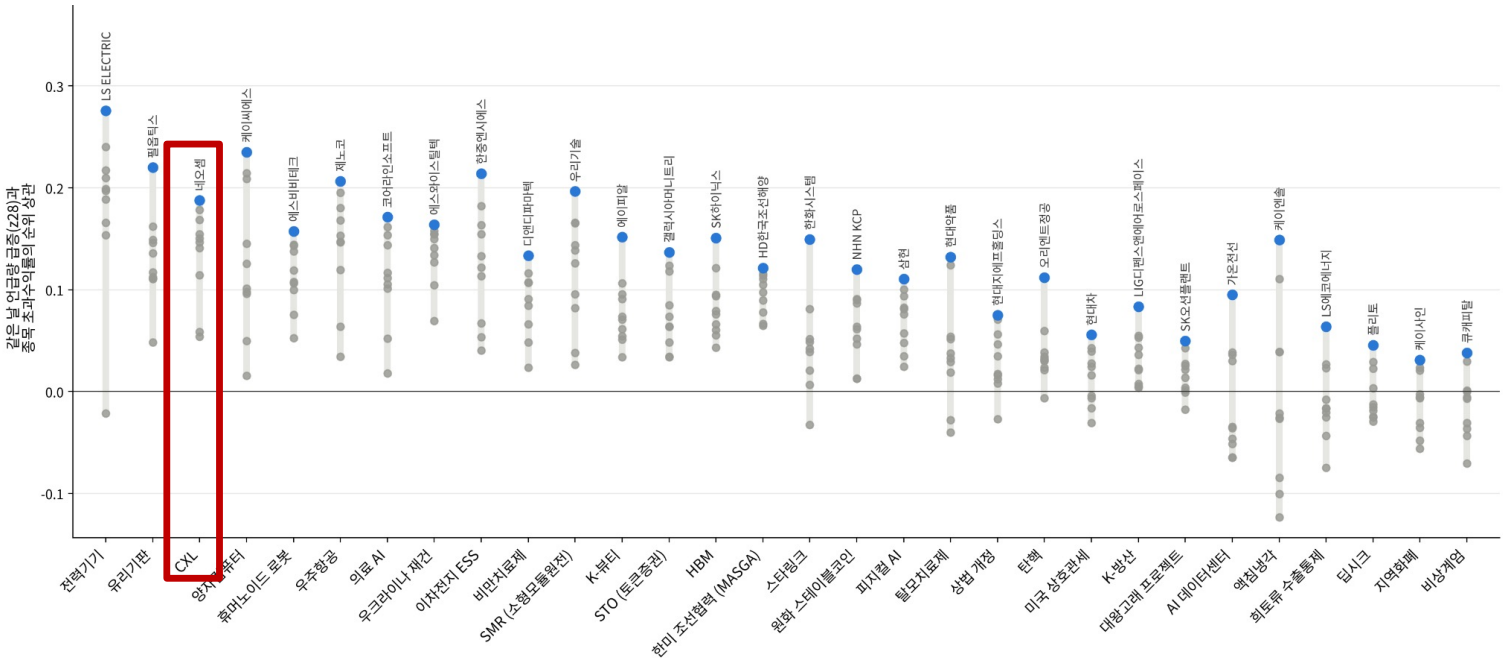
단기 급등 y = 1

전체 양성 비율 11.4%

04 EDA 1

SNS 언급량과 주가가 함께 움직이나?

SNS 언급량과 주가 수익률 간 상관관계 분석



● : 키워드 내 1위 종목

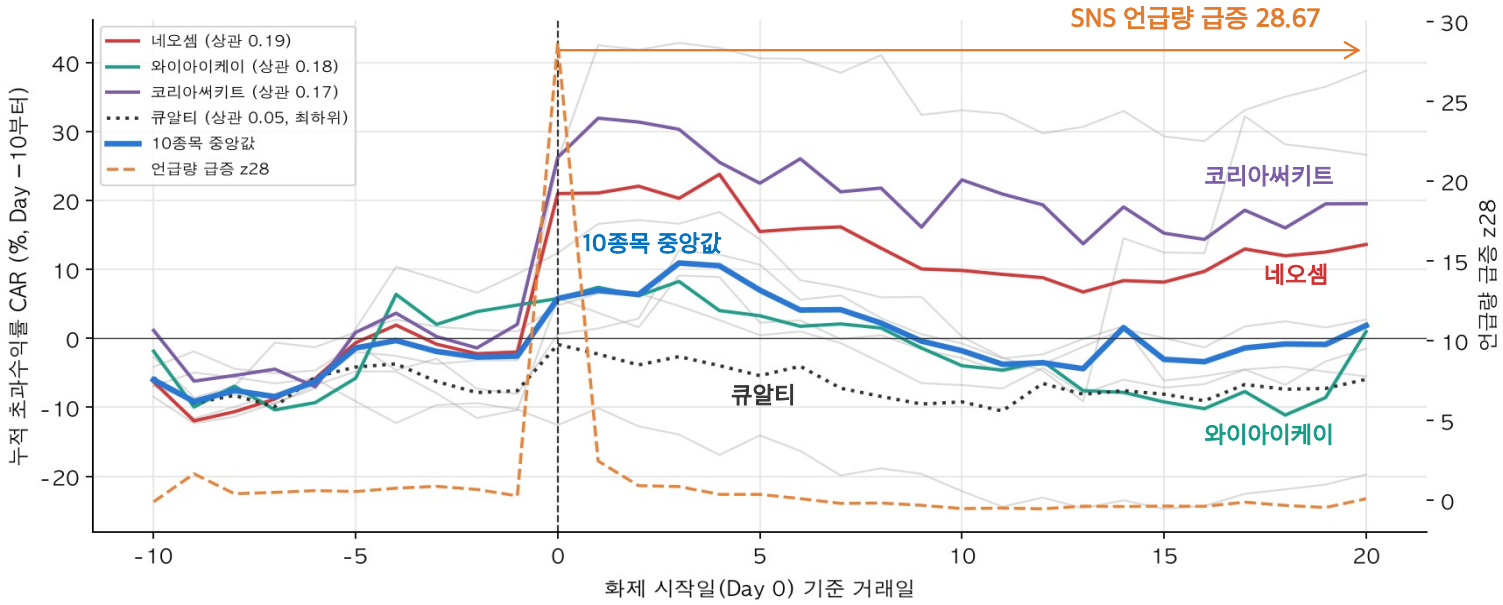
● : 키워드 내 그 외 종목

동일 키워드의 언급량 급증에도 종목별 초과수익률과의 상관은 상이

04 EDA 1

SNS 언급량과 주가가 함께 움직이나?

CXL 테마 화제 발생 전후 종목별 주가 반응



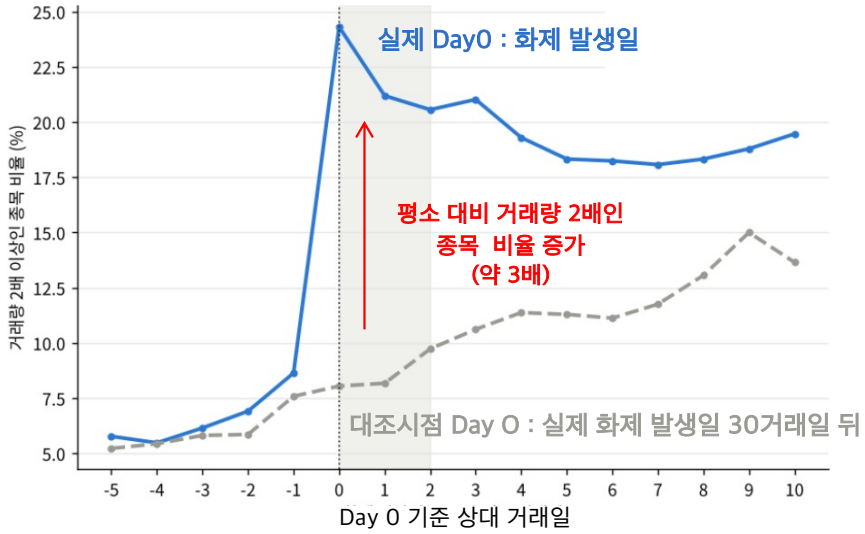
네오셈, 코리아써키트, 와이아이케이 : 화제 직후 주가가 함께 급등 (CAR 초과수익률 상승).
큐알티: 동일한 CXL 테마로 묶여 있음에도 주가가 거의 움직이지 않거나 하락.

04 EDA 2

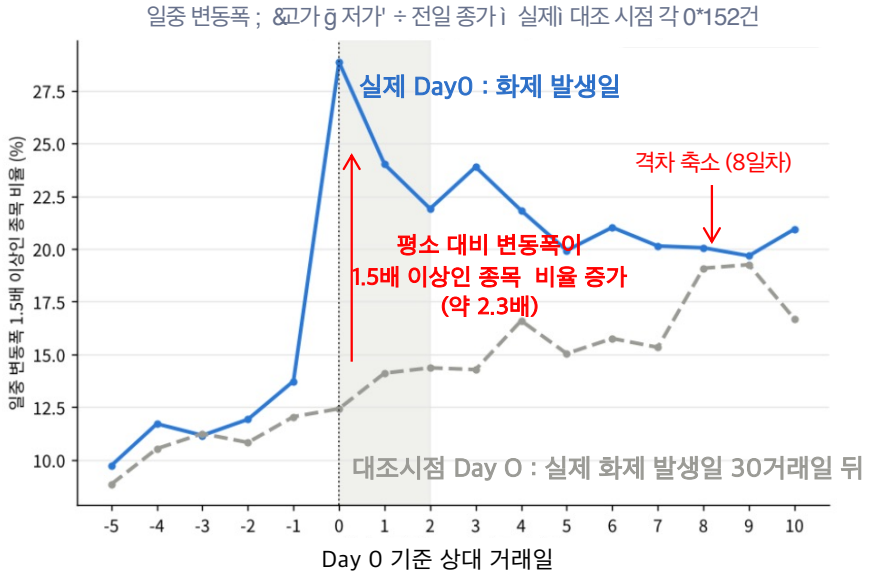
화제가 터지면 사람들이 더 많이 사고팔까?

화제 발생에 따른 거래량 및 변동성 변화 분석

[거래량 2배 이상 종목 비율 (%)]



[일중 변동폭 1.5배 이상 종목 비율 (%)]



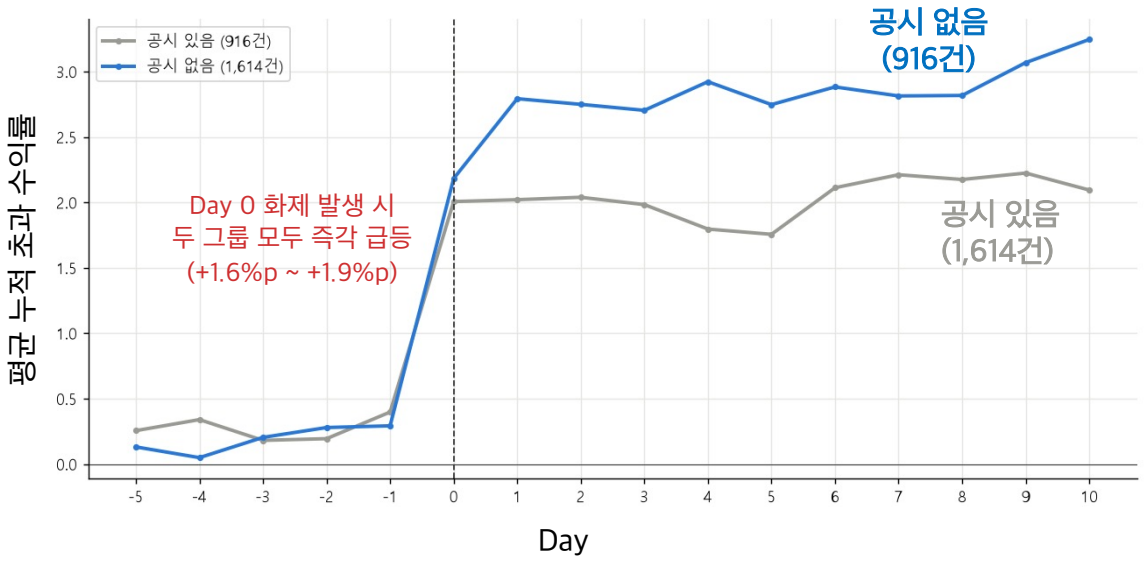
화제 발생 후 거래량과 변동성은 즉시 폭발하며, 2주간 지속되나 추가 상승을 보장하지 않음

04 EDA 3

회사 공시(호재)없이도 주가 급증이 있나?

공시 유무에 따른 주가 반응 분석

[공시 유무별 전체 주가 흐름]



※ 그래프는 전체 이벤트 평균

[같은 화제 내 수익률 비교]

두 그룹이 모두 있는 235개의 화제 발생일 대상

공시 없음 그룹 평균 초과수익률 — **공시 있음 그룹** 평균 초과수익률

두 그룹의 차이를 구한 뒤, 235개 차이를 검정

+0.33%p

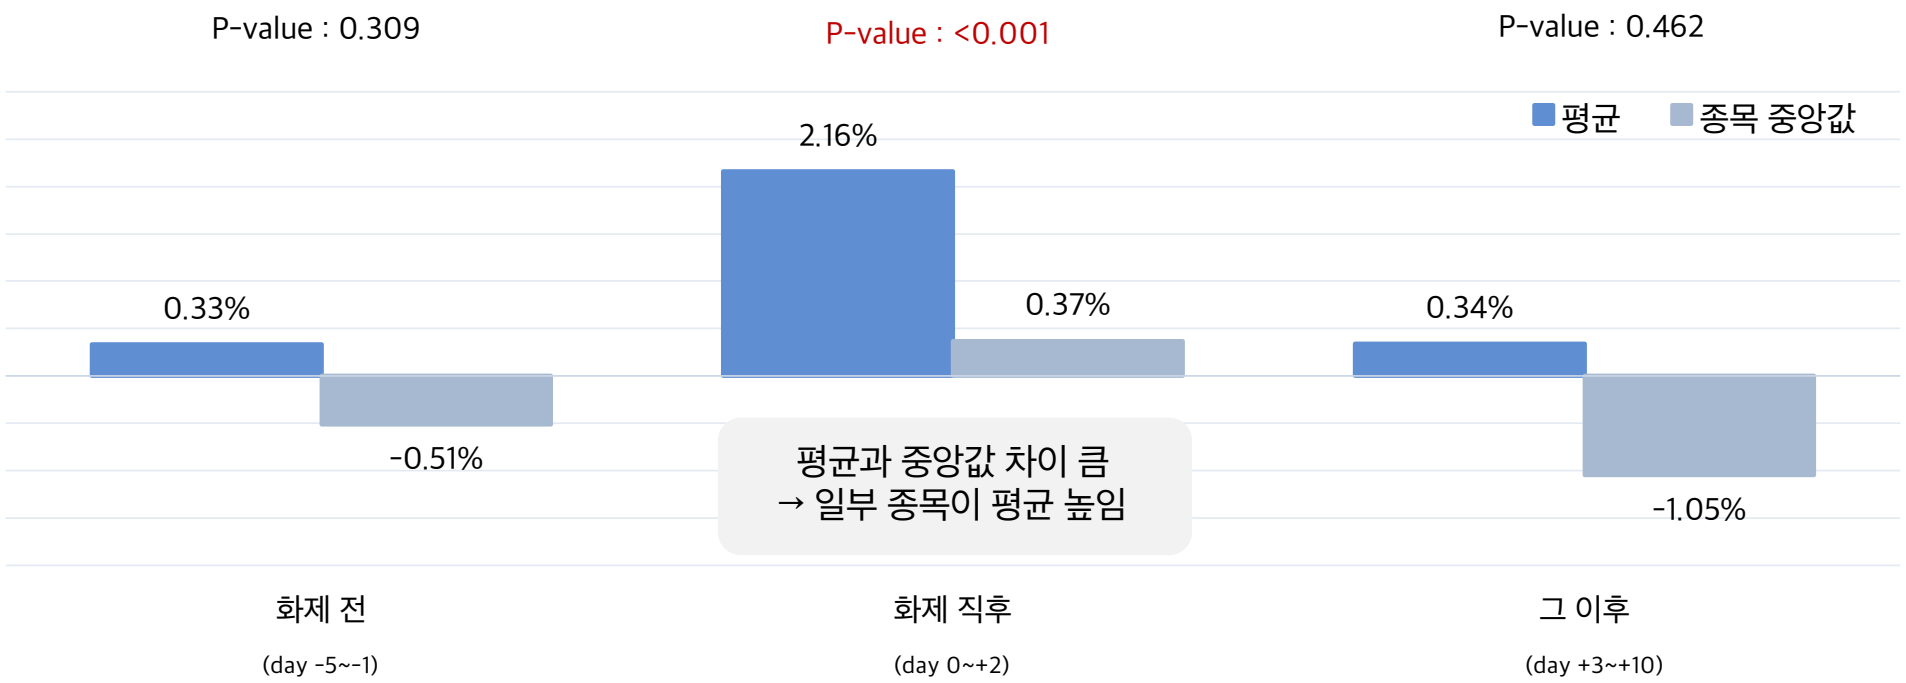
통계적의로 유의하지 않음
→ 즉, 공시가 있으나 없으나 상승폭은 거의 동일함

'공시(기업 호재)'없는 주가 급등이 이루어 지는 경우가 많음

04 EDA 4

화제 발생 시점을 기준으로 주가가 오른 시점은?

화제 전후 구간별 누적 초과수익률 분석



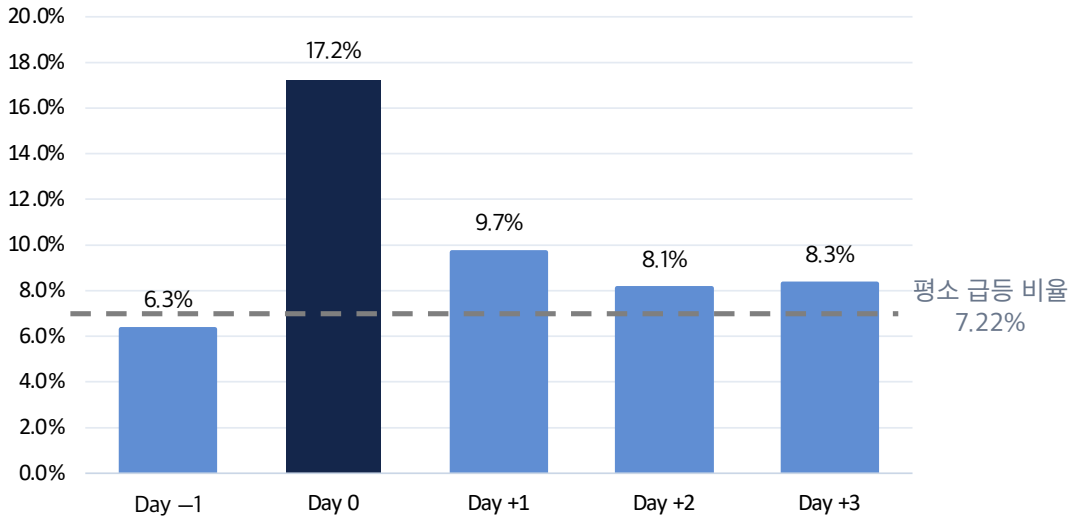
화제 직후 주가 상승이 이루어지며, 종목별 상승폭 상이

04 EDA 5

화제를 보고 따라 사면 어떻게 될까?

화제 발생 시점과 실제 매수 시점(다음 날 시가)에 따른 수익률 분석

일별 +5% 급등 종목 비율 추이(%)



Day 0 다음 날 시가 진입 시 보유기간 별 성과

보유기간	평균 초과수익률 (종가)
1거래일	–0.39%
2거래일	–0.42%
3거래일	–0.46%
5거래일	–0.42%

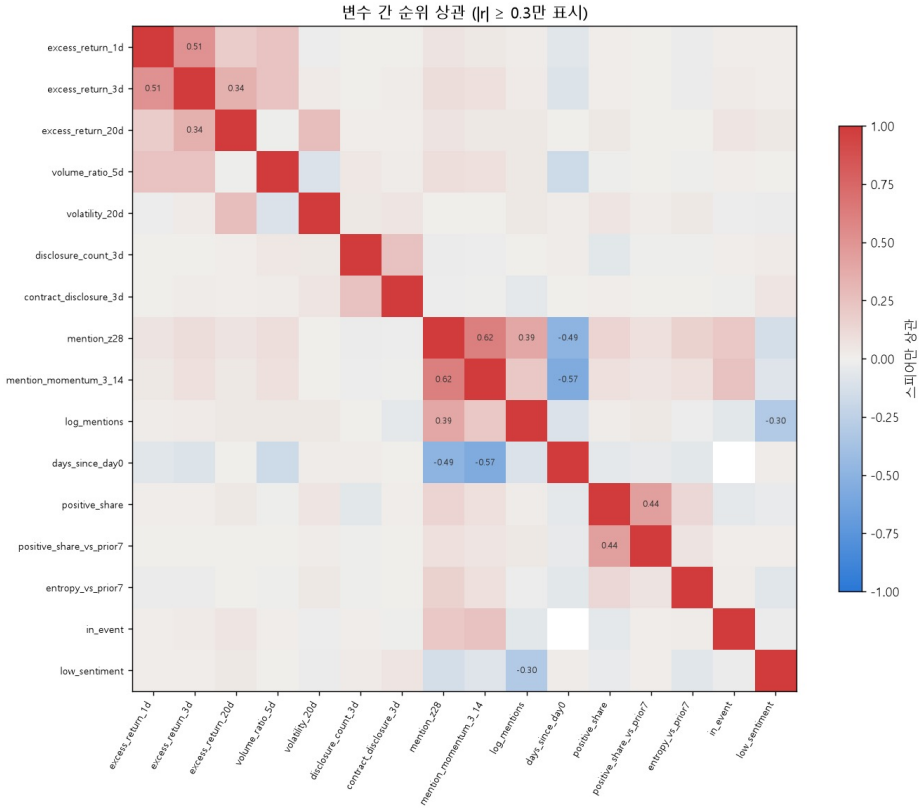
다음 날 종목 시가 갭 +0.81%
평소 대비 차이 p값 > 0.05

화제 효과는 시작 당일과 다음날 시가에 이미 반영되어, 다음날 시가에 사면 평소와 차이 없음

04 EDA 6

변수 간 상관관계 분석 및 다중공선성 검증

변수 간 과도한 중복 정보로 인한 모델 오버피팅 및 왜곡을 방지하기 위해 스피어만 순위 상관계수로 변수 간 독립성 검증



높은 순위상관(|ρ| ≥ 0.7) 변수쌍

0쌍

상관 절댓값 상위 5쌍

변수 1	변수 2	ρ
28일 표준점수	3·14일 모멘텀	+0.62
3·14일 모멘텀	화제 시작 후 경과일	−0.57
1일 초과수익률	3일 초과수익률	+0.51
28일 표준점수	화제 시작 후 경과일	−0.49
긍정 감성 비율	긍정 비율 변화	+0.44

시장 7개 + SNS 9개, 총 16개 입력 변수 유지

05 머신러닝

예측 목표와 급등 정답 정의

[EDA 관점]

화제와 주가 급등의 연관성

[머신러닝 예측 목표]

미래 기간의 종목별 급등 가능성

[거래일 기준 피처 생성 및 진입 시점]

t일	t+1일	t+2일
시장 7개 + SNS 9개 당일까지의 정보 입력	다음 거래일 시가 기준 진입	두 번째 거래일 종가까지의 수익률

정답(Target Label) 기준

시장 대비 초과 수익률 +5% 이상

y = 1

[분석 표본]

143,045행

제외: y를 계산할 수 없는 마지막 2거래일, 거래정지일

[전체 양성 비율]

11.4%

급등 기준을 충족한 관측 비율

[예측 기간 설정]

2거래일

단기 예측과 급등 표본 확보 고려

05 머신러닝

예측 모델 구성 및 학습 방법

[모델 구성]

A 시장 변수 7개
일반적인 주가 변동 요인

B 시장 7개 + SNS 9개
SNS 정보 추가

C SNS 변수 9개 (참고)
SNS 단독 예측

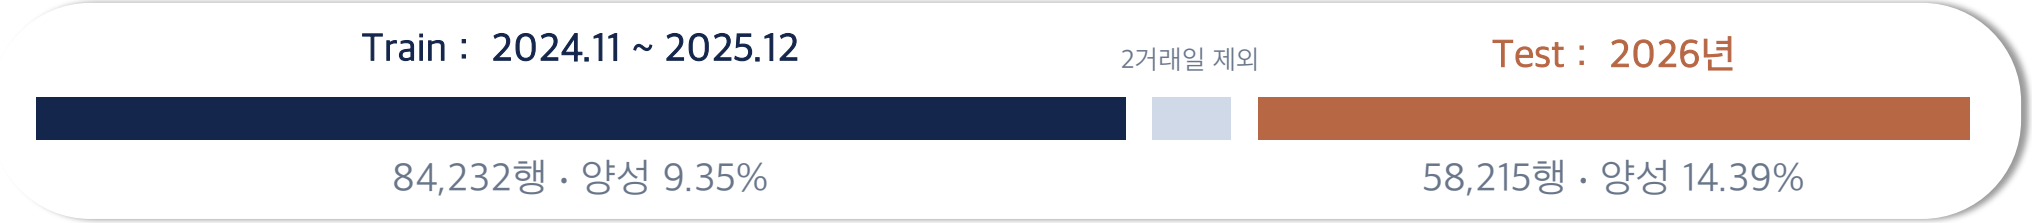
B – A → 시장 변수에 SNS 정보를 추가했을 때의 예측 성능 변화 확인

[LightGBM 선정 근거]

특성	활용 이유
비선형 관계 학습	언급량이 특정 수준을 넘을 때 나타나는 주가 반응도 학습 가능
스케일링 불필요	언급량·수익률 등 단위와 범위가 다른 변수를 별도 정규화 없이 활용

05 머신러닝

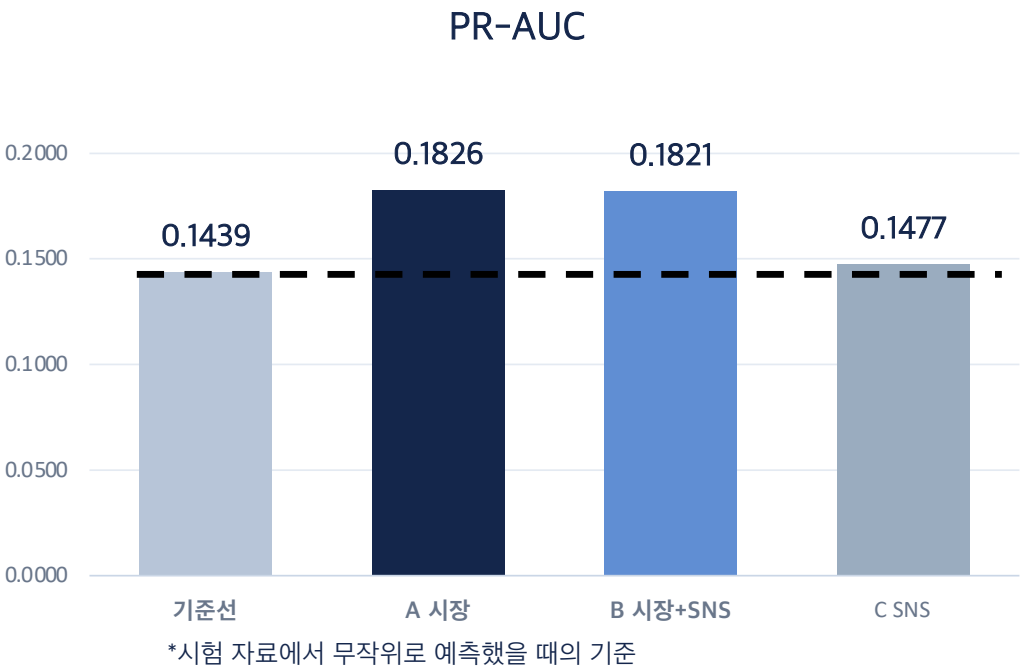
학습·시험 기간 구분 및 평가 기준



무작위 분할 시 미래 데이터를 학습 후 평가할 가능성 존재 > 시간 순으로 분할

평가지표	정의	활용 목적
PR-AUC (AP)	급등 종목을 얼마나 정확하게, 얼마나 많이 찾아냈는지 종합 평가	급등 탐지 성능의 주 지표
상위 10% 정밀도	급등 예측 확률 상위 약 10% 중 실제 급등한 비율	우선 선별한 종목의 적중률 평가
ROC-AUC	급등한 종목과 급등하지 않은 종목을 얼마나 잘 구별했는지 평가	급등·비급등 구분 성능의 보조 지표

모델 평가



*시험 자료에서 무작위로 예측했을 때의 기준

모델	상위 10% 정밀도
기준선	14.39%
A 시장	20.94%
B 시장+SNS	20.80%
C SNS	14.77%

B − A = −0.0005

95% 신뢰구간 −0.0037 ~ +0.0023

SNS 변수 추가에 따른 미래 주식 급등 예측 성능 개선 효과 없음

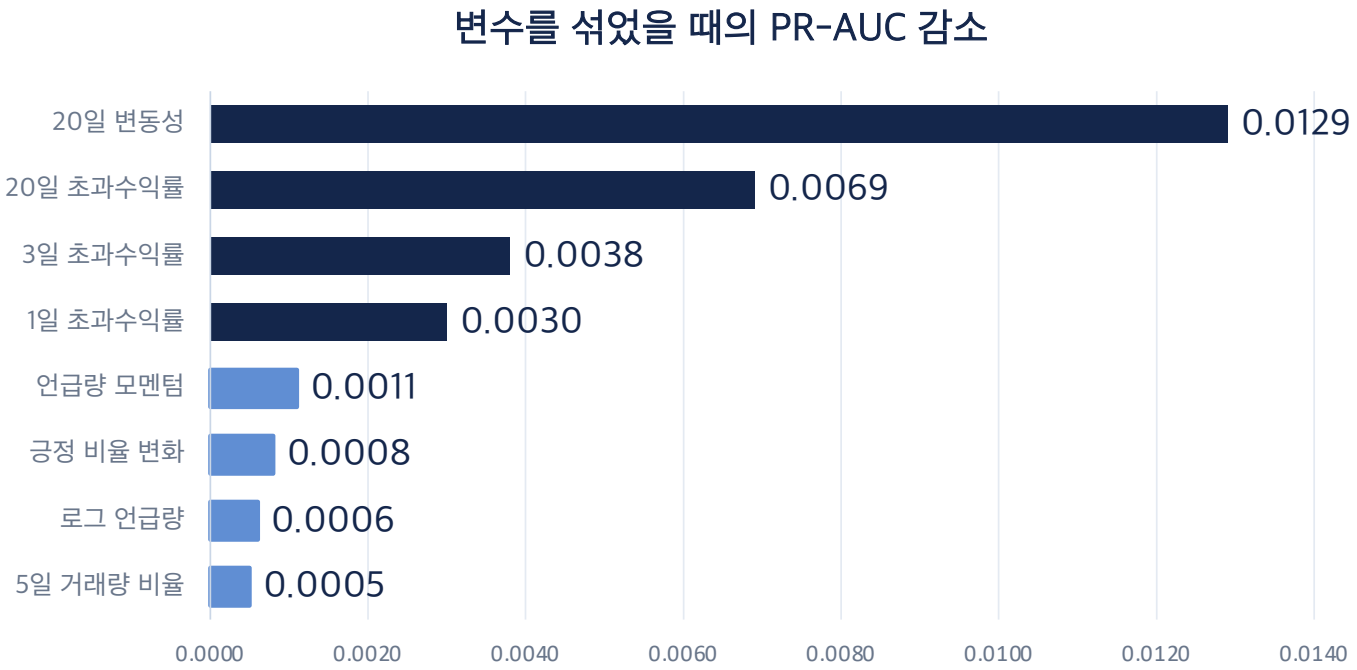
시간 이동 검증

TRAIN	TEST	양성 비율	A	B	B − A	95% 신뢰구간
~2025 상반기	2025 하반기	7.75%	0.1433	0.1415	−0.0018	−0.0062 ~ +0.0028
~2025 하반기	2026 상반기	13.08%	0.1806	0.1820	+0.0014	−0.0028 ~ +0.0056
~2026 상반기	2026 하반기	16.33%	0.1867	0.1877	+0.0010	−0.0036 ~ +0.0063

시험 기간을 바꿔도 유사한 결과 : 예측 효과 높아지지 않음

05 머신러닝

순열 중요도 : 실제로 예측에 기여한 변수는 무엇인가



상위 4개

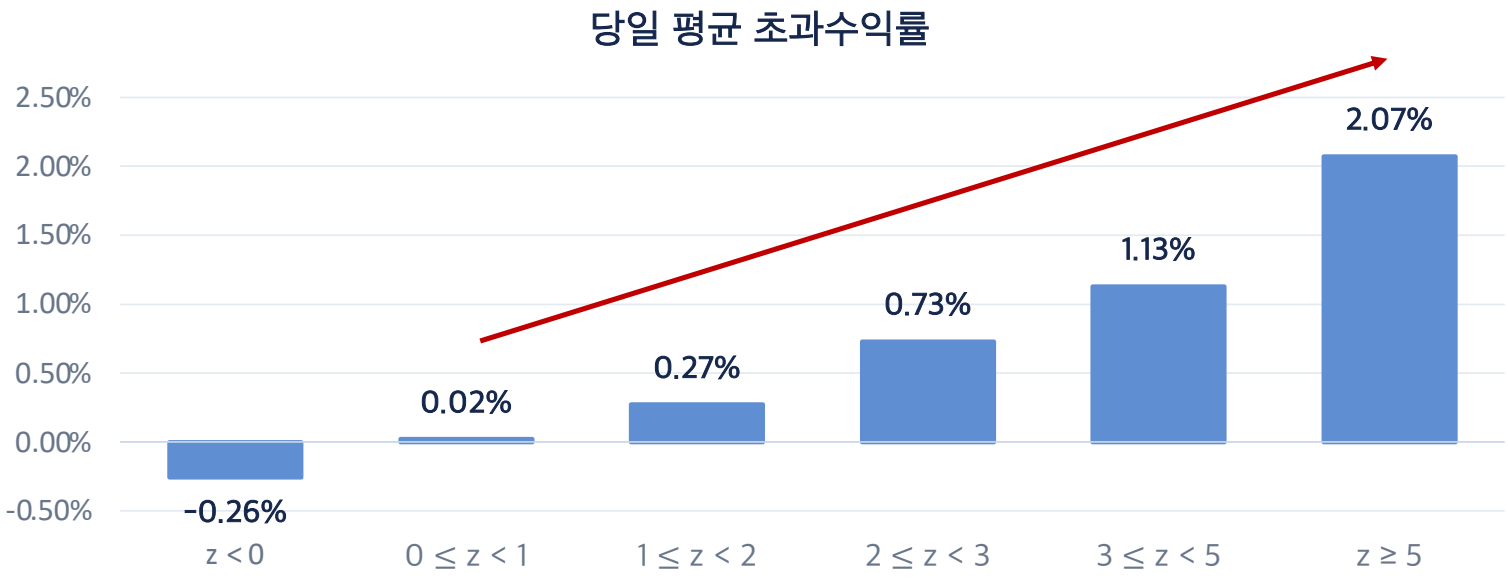
가격·변동성 변수

SNS 변수의
개별 기여는 작음

예측력은 20일 변동성과 최근 한 달 추세에서 나옴

SNS 언급량에 따른 초과수익률 변화

OLS(최소제곱법) 사용 : 다른 조건이 같을 때, X가 늘면 Y가 얼마나 변하나를 계수로 보여주는 선형회귀법



$p < 0.001$

같은 날 연관
인과 방향은 미확인

평소보다 언급이 크게 늘어난 날일수록 당일 초과수익률도 높음

급등 기준 변경에 대한 민감도 : y값 정의에 따라 예측 성능이 변경되나?

PR-AUC 차이 B − A

초기 모델 기준

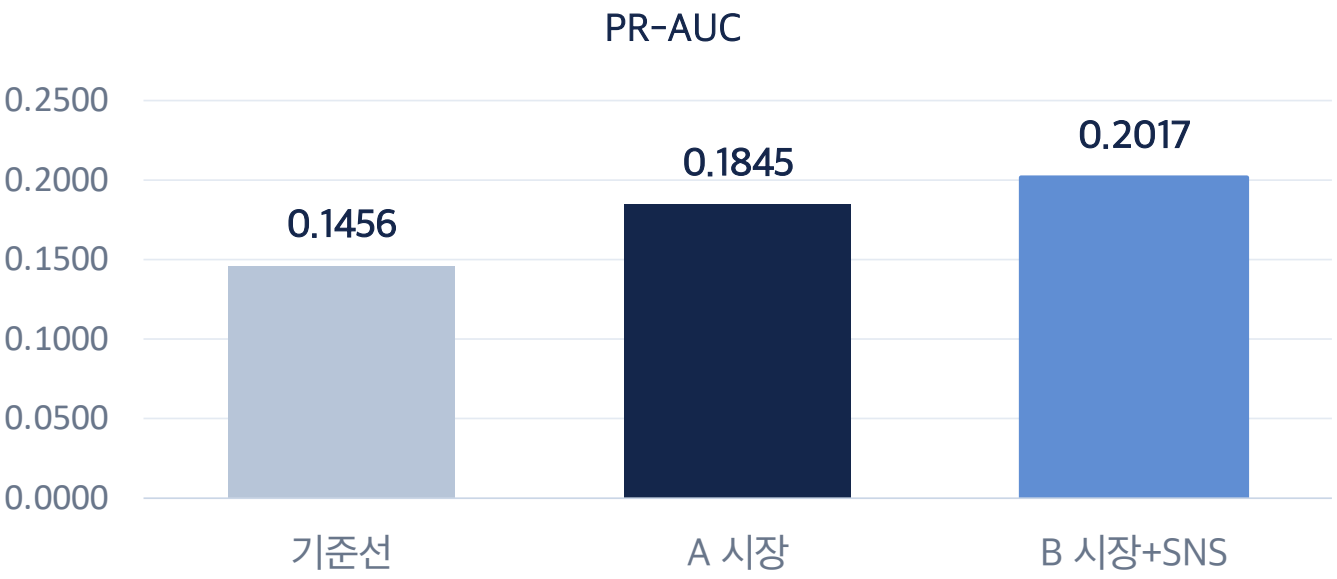
기간 / 기준	+3%	+5%	+7%	+10%
1거래일 후	−0.0008	−0.0006	+0.0001	−0.0005
2거래일 후	+0.0008	−0.0005	−0.0004	+0.0011
3거래일 후	−0.0021	−0.0020	−0.0025	−0.0032
5거래일 후	−0.0036	−0.0032	−0.0027	−0.0008

16개 조건에서 B모델에서 유의한 개선 없음

05 # 머신러닝

모델 검증

화제 직후(0~2일) 표본만으로 재평가



화제 직후 시험 표본

2,095행

B-A

+0.0172

표본량이 적어 유의미한 성과라고 보긴 어려움

05 머신러닝

SNS 변수 구성을 바꾼 결과

변수 구성	주 분할	2025 하반기	2026 상반기	2026.07~10
기존 SNS 9개	−0.0005	−0.0018	+0.0014	+0.0010
미사용 변수 추가 · SNS 13개	−0.0005	−0.0013	+0.0024	+0.0015
감성 제외 · SNS 6개	−0.0015	−0.0032	−0.0001	+0.0001
언급량 변수 3개	−0.0008	−0.0045*	+0.0010	+0.0008
언급 급증 z28만	+0.0009	−0.0029*	+0.0020	−0.0003
A + 부정 비율 변화	+0.0020*	+0.0006	+0.0026*	+0.0006
A + 정점 후 경과일	+0.0023*	+0.0004	+0.0039*	−0.0005

* 해당 기간에서 통계적으로 유의한 차이

일부 기간의 작은 개선이 있으나, 다른 기간에서 일관되게 재현되지 않음

다른 모델 비교

모델	A	B	B − A	판정
LightGBM (기존 모델)	0.1826	0.1821	-0.0005	차이 없음
로지스틱 회귀	0.1778	0.1781	+0.0003	차이 없음
랜덤포레스트	0.1842	0.1830	−0.0012	차이 없음
LSTM · 반복 1	0.1912	0.1810	−0.0102	B가 낮음
LSTM · 반복 2	0.1937	0.1773	−0.0164	B가 낮음
LSTM · 반복 3	0.1912	0.1774	−0.0137	B가 낮음

LSTM는 SNS 우연한 패턴에 과적합한 것으로 보임

LightGBM에 한정된 결과는 아님

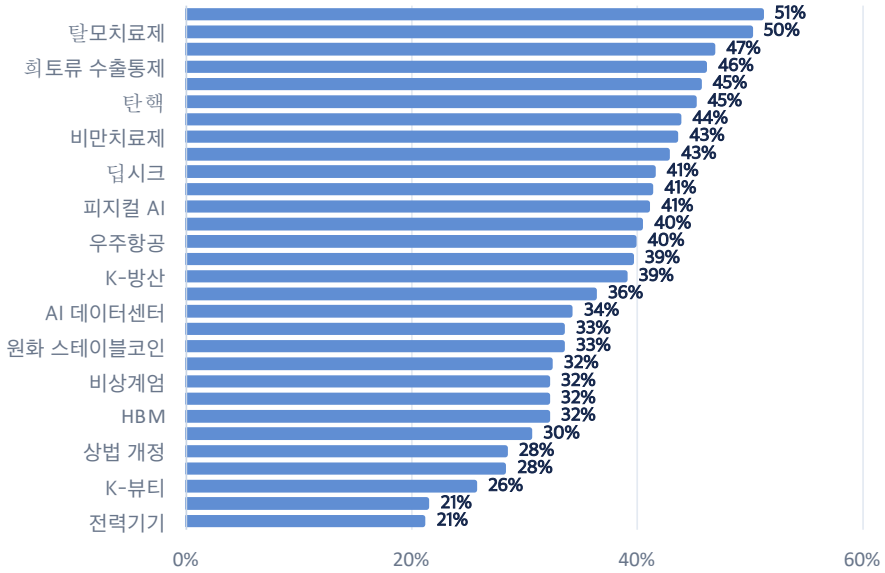
A

보완 분석 : 급등 이후 붕괴에 대한 SNS의 예측력

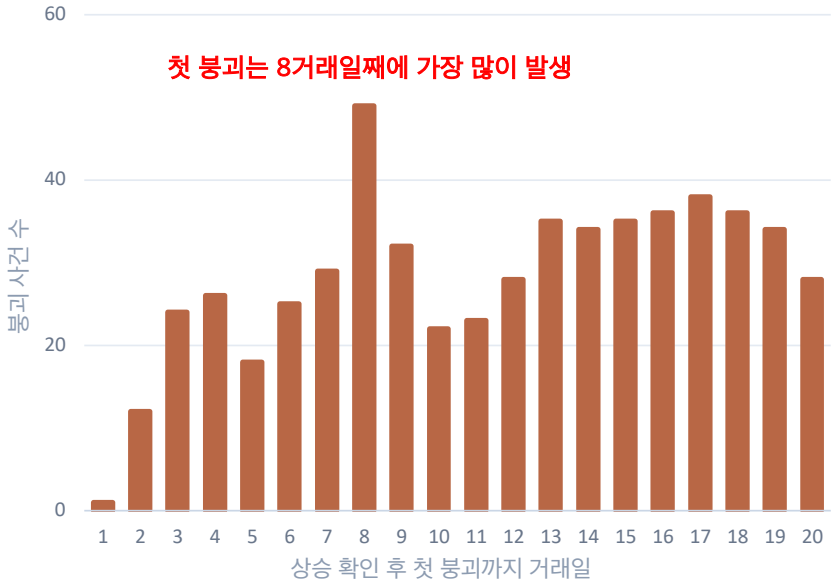
급등 이후 붕괴* 비율과 발생 시점

*고점 대비 종가 20% 하락

[급상승 종목 중 한달 내 다시 원래 주가로 복귀한 비율]



[상승 확인 후 첫 붕괴 시점]



급등 사례의 3분의 1 이상이 붕괴, 첫 상승 후 8일 째 가장 많은 붕괴 발생 → 테마주 상승은 쉽게 꺼짐

A

보완 분석 : 급등 이후 붕괴에 대한 SNS의 예측력

SNS 관심 감소·부정 증가에 따른 붕괴 비율 비교

[SNS 신호 기준]

직전 7일과 비교해 최근 7일의

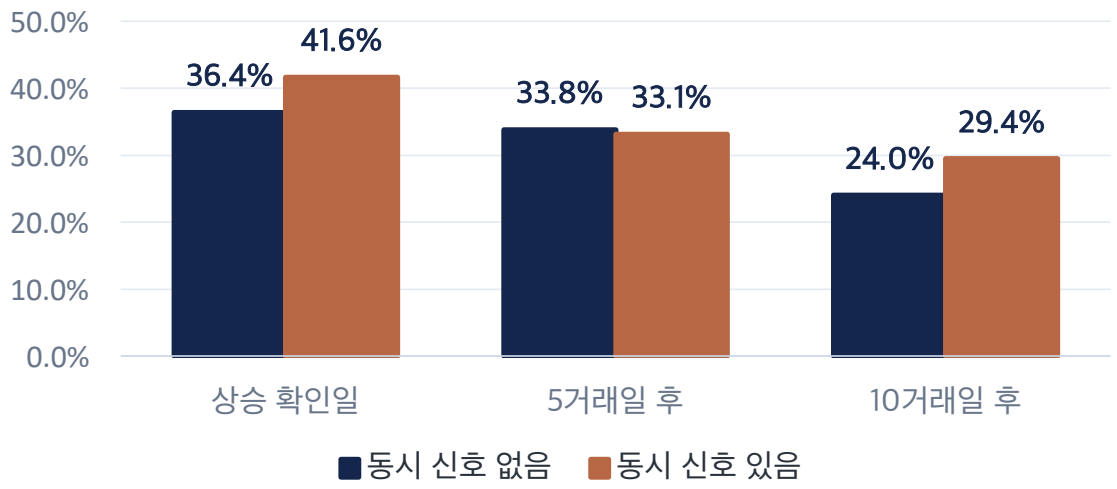
① 평균 언급량 감소

② 부정 감성어 비율 증가

신호 있음: 한 조건 이상 충족

신호 없음: 두 조건 모두 미충족

[SNS 신호 유무별 이후 붕괴 비율]



SNS 신호 (관심 감소와 부정 표현 증가)는 붕괴를 예측하기 어려움

06 대시보드


DASHBOARD
SNS 화제성은 주가 급등의 선행 신호인가?
Deploy
홈
종합 대시보드
주식 차트
데이터 소개
모델 소개
분석 피드
2조
SOCIAL BUZZ × MARKET INTELLIGENCE
주식·SNS 분석 대시보드
KOSPI
6,007.78
▲ +369.44 (+6.55%) (전일대비)
KOSDAQ
765.59
SNS 화제성과 주가 반응
SNS 언급량 증가
주가 급등
분석 구성
언급량과 수익률
키워드·종목별 SNS 언급량과 초과수익률의 관계
화제 전후 반응
실제·가짜 화제 시점의 거래량과 변동폭 비교
급등 이후 신호
급등 이후 붕괴와 SNS 감성·뉴스 동행 분석
모델링 · 예측 성능 검증
시장 변수에 SNS 변수를 더했을 때의 예측 성능 비교
연구팀 소개
캐릭터를 눌러 팀원 소개를 확인하세요.

07 요약

동반 반응	**언급 급증과 당일 주가 상승의 연관** 산업 테마에서 상대적으로 뚜렷
반응 시점	**주가 상승은 화제 직후에 집중** 다음 날 시가 이후 추가 상승 미확인
추가 예측력	**SNS 언급이 미래 주식 급등 예측은 불가** 기간·정답·알고리즘 변경에도 대체로 유사

온라인 관심은 시장 반응을 설명하는 단서 , 이후 급등 예측은 별도 검증

08 한계

데이터 범위

키워드 30개, 종목 10개로 데이터 범위 좁음
다른 테마 및 기간에서도 재검증 필요

SNS 데이터

하루 합계 데이터로 SNS, 주가 선후 관계 확인 불가
언급의 배경/맥락 파악 어려움

원인 해석

SNS와 주가의 명확한 인과관계 파악 불가
공시 건수만으로 호재·악재 판별 어려움

수익률 계산

코스닥, 코스피 지수의 시가 자료 부재로
시장수익률을 종목과 같은 시점으로 빼지 못함

E.O.D

감사합니다.

https://github.com/DonggukKim0/KeywordDrivenVolatility